



INSTITUTO TECNOLÓGICO
DE CIUDAD MADERO

ITCM



TECNM
TECNOLÓGICO NACIONAL DE
MÉXICO

Materia: Programacion para Big Data

Horario: 13:00 – 14:00

Docente: Jorge Peralta Escobar

Algoritmos de aprendizaje no supervisado

Nombres	No. de control
Arizabalo Cepeda Erick Emmanuel	22070287
Reyna Montaña Francisco Gabriel	22070272

Periodo Escolar:

Enero – Julio 2026

Introducción Al Aprendizaje Automático No Supervisado

El **Aprendizaje No Supervisado (Unsupervised Learning)** constituye un paradigma esencial dentro del Machine Learning en el cual los algoritmos se enfrentan a conjuntos de datos que carecen de etiquetas previas (*unlabeled data*). A diferencia del aprendizaje supervisado, donde el sistema intenta aproximar una función objetivo conocida a partir de pares de entrada-salida, en el aprendizaje no supervisado el objetivo es identificar estructuras intrínsecas, patrones ocultos, agrupaciones naturales y relaciones dimensionales latentes en los datos históricos.

La premisa fundamental de este paradigma radica en la autoorganización. El algoritmo explora la topología del espacio de características para modelar la distribución subyacente de los datos.

El Proceso de Desarrollo en Aprendizaje No Supervisado

1. **Recolección y Limpieza de Datos:** Obtención de los datos en bruto y tratamiento de valores nulos o inconsistentes.
2. **Preprocesamiento y Normalización:** Debido a que la mayoría de los algoritmos de este tipo se basan en métricas de distancia (como la distancia euclidiana), el escalado y estandarización de las variables numéricas es un paso mandatorio para evitar el sesgo por diferencias de magnitudes.
3. **Reducción de Dimensionalidad (Opcional pero recomendado):** Compresión del espacio de características para facilitar la visualización y mejorar la eficiencia computacional.
4. **Aplicación del Algoritmo:** Ejecución de modelos de agrupamiento (clustering) o asociación.
5. **Evaluación de Resultados:** Inspección interna mediante métricas de cohesión y separación (como el coeficiente de silueta o la inercia) y análisis cualitativo del perfil de los grupos obtenidos.

Desarrollo Y Funcionamiento De Los Algoritmos

A continuación se detallan los tres métodos fundamentales del aprendizaje no supervisado seleccionados para el análisis de los compuestos químicos del vino:

Agrupamiento por K-Medios (K-Means Clustering)

- **Concepto:** Es un algoritmo de particionamiento iterativo que divide un conjunto de N observaciones en K clústeres disjuntos, donde cada observación pertenece al clúster con el centroide más cercano.
- **Desarrollo y Funcionamiento:**
 1. Se seleccionan inicialmente K centroides de forma aleatoria (o mediante técnicas de optimización como K-Means++).
 2. Cada punto se asigna a su centroide más cercano utilizando la distancia euclidiana:

$$d(x, y) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2}$$

3. Se recalculan los centroides promediando las posiciones de todas las observaciones asignadas a cada grupo.
4. Los pasos 2 y 3 se repiten iterativamente hasta que la asignación de puntos no varíe o se alcance el límite de iteraciones (convergencia a un mínimo local de la suma de cuadrados intra-clase, $WCSS$):

$$WCSS = \sum_{j=1}^K \sum_{x \in C_j} ||x - \mu_j||^2$$

- **Casos de uso:** Segmentación de clientes, compresión de imágenes, detección de anomalías y agrupamiento de perfiles químicos.

Agrupamiento Jerárquico (Hierarchical Clustering)

- **Concepto:** Es un método que genera una estructura en forma de árbol (dendrograma) para representar la jerarquía de agrupaciones de las observaciones sin necesidad de predefinir el número K de antemano.
- **Desarrollo y Funcionamiento:** Puede ser divisivo (top-down) o aglomerativo (bottom-up). En el enfoque aglomerativo:
 1. Cada observación comienza constituyendo su propio clúster individual.
 2. Se calculan las distancias mutuas entre todos los clústeres.
 3. Se fusionan consecutivamente los dos clústeres más cercanos utilizando un criterio de enlace (*linkage*), tales como:
 - *Single Linkage* (mínima distancia entre elementos).
 - *Complete Linkage* (máxima distancia entre elementos).
 - *Average Linkage* (distancia promedio).
 - *Ward's Method* (minimiza el incremento de la varianza total dentro de los grupos en cada fusión).
 4. El proceso continúa hasta que todos los puntos se han fusionado en un único clúster raíz. El analista examina el dendrograma para realizar un "corte" a la altura deseada.
- **Casos de uso:** Taxonomía biológica, análisis filogenético, estructuración de perfiles de consumo y minería de texto.

Análisis de Componentes Principales (PCA)

- **Concepto:** Técnica matemática de reducción de dimensionalidad lineal que transforma un conjunto de variables correlacionadas en un nuevo espacio de variables incorrelacionadas llamadas Componentes Principales (CP).

- **Desarrollo y Funcionamiento:**

1. Se centra y estandariza la matriz de datos original X de tamaño $N \times P$.
2. Se calcula la matriz de covarianza (o correlación) C .
3. Se obtienen los valores propios (λ_i) y vectores propios (v_i) de dicha matriz resolviendo la ecuación característica:

$$Cv_i = \lambda_i v_i$$

4. Los vectores propios representan las direcciones de máxima variabilidad (componentes principales), mientras que los valores propios indican la cantidad de varianza capturada por cada componente.
 5. Se proyectan los datos sobre las primeras M componentes ($M < P$), logrando retener la mayor cantidad de información matemática (varianza) con una dimensión significativamente menor.
- **Casos de uso:** Visualización de datos multidimensionales, preprocesamiento para mitigar la maldición de la dimensionalidad, y filtrado de ruido en señales y espectrometría.

Aplicación De Los Algoritmos En La Práctica

Utilizaremos el conjunto de datos de vino proporcionado (WineQT.csv). Este dataset contiene mediciones químicas correspondientes a muestras de vino tinto. Para un enfoque puramente no supervisado, se omitirá el identificador único (Id) y se aislará la variable quality (calidad) para usarla únicamente al final del flujo como mecanismo de validación bi-dimensional y ver si los clústeres químicos coinciden de algún modo con las categorías de calidad asignadas por los catadores.

Preprocesamiento y Análisis Exploratorio de Datos (EDA)

Es imperativo escalar los datos, dado que variables como la densidad (density, rango $0.990 - 1.003$) y el dióxido de azufre total (total sulfur dioxide, rango $6 - 289$) difieren en varios órdenes de magnitud, lo que anularía el efecto de las variables de menor escala si se calculan distancias euclidianas directamente.

Análisis De Resultados Y Código En R

El código en R implementa un flujo completo de Ciencia de Datos:

1. **Estandarización multivariada.**

```

1 # =====
2 # PROGRAMACIÓN PARA BIG DATA / CIENCIA DE DATOS
3 # ALGORITMOS DE APRENDIZAJE NO SUPERVISADO EN R
4 # =====
5 # Integrantes: Erick Emmanuel Arizabalo Cepeda, Francisco Gabriel Reyna Montaña
6 # Docente: Jorge Peralta Escobar
7 # Periodo Escolar: Enero - Julio 2026
8 # =====
9
10 # -----
11 # PREPARACIÓN DE ENTORNO Y INSTALACIÓN/CARGA DE LIBRERÍAS
12 # -----
13 # Descomentar si es necesario instalar los paquetes requeridos
14 # install.packages(c("tidyverse", "cluster", "factoextra", "gridExtra"))
15
16 library(tidyverse) # Manipulación de datos y visualización elegante (ggplot2)
17 library(cluster)   # Funciones avanzadas de agrupamiento (silhouette, pam)
18 library(factoextra) # Extracción y visualización interactiva de análisis multivariante
19 library(gridExtra)  # Organización de gráficos en cuadrículas
20
21 # -----
22 # CARGA Y PREPROCESAMIENTO DE DATOS (ANÁLISIS EXPLORATORIO - EDA)
23 # -----
24 # Carga del dataset WineQT
25 if (file.exists("WineQT.csv")) {
26   datos_raw <- read.csv("WineQT.csv")
27 } else if (file.exists("WineQT.csv.csv")) {
28   datos_raw <- read.csv("WineQT.csv.csv")
29 } else {
30   stop("El archivo WineQT.csv no ha sido encontrado en el directorio actual.")
31 }
32
33 # Eliminación de columna identificadora 'Id'
34 datos_limpios <- datos_raw %>% select(-Id)
35
36 # Verificación de estructura inicial del dataset
37 cat("=== ESTRUCTURA DEL DATASET DE VINOS ===\n")
38 print(str(datos_limpios))
39
40 # Separación de características químicas y variable explicativa 'quality'
41 # Guardamos la variable quality para validación cruzada cualitativa
42 calidad_original <- datos_limpios$quality
43 características_químicas <- datos_limpios %>% select(-quality)
44
45 # Estandarización de variables (z-score scaling)
46 # Crucial para evitar sesgos por escalas numéricas dispares en el cálculo de distancias
47 datos_escalados <- as.data.frame(scale(características_químicas))
48
49 cat("\n=== DATOS QUÍMICOS ESCALADOS (MUESTRA) ===\n")
50 print(head(datos_escalados, 3))
51
52 # Fijación de semilla de aleatoriedad para asegurar reproducibilidad
53 set.seed(42)
54
55 # -----
56 # DETERMINACIÓN DEL NÚMERO ÓPTIMO DE CLÚSTERES (K)
57 # -----
58 # Determinación de K por el Método del Codo (WSS - Within Cluster Sum of Squares)
59 grafico_codo <- fviz_nbclust(datos_escalados, kmeans, method = "wss") +
60   labs(title = "Método del Codo (WSS)",
61        subtitle = "Selección de K basado en la reducción de inercia",
62        x = "Número de Clústeres (K)", y = "Suma de Cuadrados Intra-Clúster") +
63   theme_minimal()
64
65 # Determinación de K por el Método de la Silueta (Silhouette Coefficient)
66 grafico_silueta <- fviz_nbclust(datos_escalados, kmeans, method = "silhouette") +
67   labs(title = "Método de la Silueta",
68        subtitle = "Selección de K basada en la cohesión y separación media",
69        x = "Número de Clústeres (K)", y = "Ancho de Silueta Promedio") +

```

```

70 theme_minimal()
71
72 # Guardar ambos gráficos comparativos en un archivo PNG
73 cat("\n[Guardando gráfico del Método del Codo y Silueta en 'metodo_codo_silueta.png'...]\n")
74 png("metodo_codo_silueta.png", width = 1000, height = 500, res = 120)
75 grid.arrange(grafico_codo, grafico_silueta, ncol = 2)
76 dev.off()
77
78 # -----
79 # ALGORITMO 1: K-MEANS CLUSTERING (K-MEDIOS)
80 # -----
81 # Basándonos en el análisis previo, seleccionamos un K óptimo de 3 clústeres
82 k_optimo <- 3
83 cat(paste("\n--- Ejecutando K-Means con K =", k_optimo, "---\n"))
84
85 modelo_kmeans <- kmeans(datos_escalados, centers = k_optimo, nstart = 25)
86
87 # Adición de los resultados de clustering al dataframe original
88 datos_agrupados <- datos_limpios %>%
89   mutate(Cluster_KMeans = factor(modelo_kmeans$cluster))
90
91 # Análisis de centroides (perfiles químicos promedio por clúster)
92 cat("\n=== PERFIL DE CENTROIDES QUÍMICOS POR CLÚSTER ===\n")
93 centroides <- datos_agrupados %>%
94   group_by(Cluster_KMeans) %>%
95   summarise(across(everything(), mean))
96 print(t(centroides))
97
98 # Visualización bi-dimensional de los clústeres de K-Means y guardar a archivo
99 plot_kmeans_clusters <- fviz_cluster(modelo_kmeans, data = datos_escalados,
100   geom = "point",
101   ellipse.type = "convex",
102   ggtheme = theme_bw()) +

```

```

103   labs(title = "Visualización de Clústeres de K-Means",
104         subtitle = "Proyección sobre los dos componentes principales de mayor varianza")
105   cat("[Guardando visualización de clústeres en 'kmeans_clusters.png'...]\n")
106   ggsave("kmeans_clusters.png", plot = plot_kmeans_clusters, width = 8, height = 6, dpi = 150)
107
108 # -----
109 # ALGORITMO 2: AGRUPAMIENTO JERÁRQUICO (HIERARCHICAL CLUSTERING)
110 # -----
111 cat("\n--- Ejecutando Agrupamiento Jerárquico Aglomerativo (Método de Ward) ---\n")
112
113 # Cálculo de la matriz de distancias euclidianas
114 matriz_distancias <- dist(datos_escalados, method = "euclidean")
115
116 # Ajuste del modelo jerárquico mediante el método de Ward
117 modelo_jerarquico <- hclust(matriz_distancias, method = "ward.D2")
118
119 # Visualización del Dendrograma y guardar a archivo
120 # Para una visualización clara del dendrograma, graficaremos una muestra aleatoria de 150 elementos
121 set.seed(42)
122 muestra_indices <- sample(1:nrow(datos_escalados), 150)
123 dist_muestra <- dist(datos_escalados[muestra_indices, ], method = "euclidean")
124 hclust_muestra <- hclust(dist_muestra, method = "ward.D2")
125
126 cat("[Guardando Dendrograma en 'dendrograma_jerarquico.png'...]\n")
127 png("dendrograma_jerarquico.png", width = 900, height = 600, res = 120)
128 plot(hclust_muestra, hang = -1, cex = 0.6, main = "Dendrograma de Agrupamiento Jerárquico (Muestra de 150 Vinos)",
129   xlab = "Muestras de Vinos", ylab = "Distancia de Fusión (Método de Ward)", sub = "")
130 # Dibujar rectángulos rojos que delimitan los 3 grupos sugeridos
131 rect.hclust(hclust_muestra, k = 3, border = "red")
132 dev.off()
133
134 # Cortar el árbol completo para obtener 3 clústeres jerárquicos
135 cluster_jerarquico_asignados <- cutree(modelo_jerarquico, k = 3)


```

```

136 datos_agrupados$Cluster_Jerarquico <- factor(cluster_jerarquico_asignados)
137
138 # -----
139 # ALGORITMO 3: ANÁLISIS DE COMPONENTES PRINCIPALES (PCA)
140 # -----
141 cat("\n--- Ejecutando Análisis de Componentes Principales (PCA) ---\n")
142
143 modelo_pca <- prcomp(caracteristicas_quimicas, scale. = TRUE)
144
145 # Resumen de varianza explicada por cada componente principal
146 cat("\n=== RESUMEN DE COMPONENTES PRINCIPALES ===\n")
147 print(summary(modelo_pca))
148
149 # Visualización del Scree Plot (Gráfico de Sedimentación) y guardar a archivo
150 scree_plot <- fviz_eig(modelo_pca, addlabels = TRUE, ylim = c(0, 40)) +
151   labs(title = "Gráfico de Sedimentación (Scree Plot)",
152        x = "Componentes Principales", y = "Porcentaje de Varianza Explicada") +
153   theme_minimal()
154 cat("[Guardando gráfico de sedimentación en 'pca_scree_plot.png'...]\n")
155 ggsave("pca_scree_plot.png", plot = scree_plot, width = 7, height = 5, dpi = 150)
156
157 # Visualización del Biplot de PCA y guardar a archivo
158 # Coloreamos las observaciones basándonos en los clústeres de K-Means calculados
159 biplot_pca <- fviz_pca_biplot(modelo_pca,
160                               label = "var", # Mostrar etiquetas solo de variables químicas
161                               col.ind = datos_agrupados$Cluster_KMeans, # Color según clúster
162                               palette = "jco",
163                               addEllipses = TRUE,
164                               ellipse.level = 0.95,
165                               legend.title = "Clúster K-Means",
166                               ggtheme = theme_minimal()) +
167   labs(title = "Biplot Multivariado del PCA",
168        subtitle = "Variables químicas (vectores de carga) y observaciones del vino")
169 cat("[Guardando Biplot del PCA en 'pca_biplot.png'...]\n")
170 ggsave("pca_biplot.png", plot = biplot_pca, width = 8, height = 6, dpi = 150)
171
172 # -----
173 # EVALUACIÓN Y VALIDACIÓN CRUZADA CON LA CALIDAD ORIGINAL (WINE QUALITY)
174 # -----
175 # Evaluamos estadísticamente si los clústeres químicos coinciden con la percepción sensorial
176 tabla_validacion <- table(KMeans = datos_agrupados$Cluster_KMeans, CalidadOriginal = calidad_original)
177 cat("\n=== RELACIÓN CRUZADA ENTRE CLÚSTERES QUÍMICOS Y CALIDAD DEL VINO ===\n")
178 print(tabla_validacion)
179
180 # Interpretación rápida del rendimiento
181 # Calculamos la calidad promedio por clúster químico
182 calidad_promedio_cluster <- datos_agrupados %>%
183   group_by(Cluster_KMeans) %>%
184   summarise(Calidad_Promedio = mean(quality), Total_Vinos = n())
185 print(calidad_promedio_cluster)
186
187 cat("\n[Proceso de Aprendizaje No Supervisado Completado Exitosamente]\n")
188 # =====

```


2. Determinación del número óptimo de clústeres utilizando el método de codo (*Elbow Method*) y el método de la silueta (*Silhouette Analysis*).



3. Agrupamiento por K-Means y análisis de centroides resultantes.


Visualización de Clústeres de K-Means

Proyección sobre los dos componentes principales de mayor varianza



4. Agrupamiento jerárquico aglomerativo con visualización de dendrograma.

Dendrograma de Agrupamiento Jerárquico (Muestra de 150 Vinos)




5. Reducción dimensional con PCA, proyectando los datos químicos sobre las dos componentes principales de mayor variabilidad y coloreándolos según el resultado de K-Means.

Biplot Multivariado del PCA

Variables químicas (vectores de carga) y observaciones del vino



Gráfico de Sedimentación (Scree Plot)



Discusión de los Resultados Obtenidos:

- Selección de K:** Los métodos matemáticos apuntan consistentemente a que $K = 3$ o $K = 4$ representa la partición óptima de los perfiles químicos del vino.
- Interpretación de Clústeres (K-Means):**
 - Clúster 1 (Vinos Ligeros y Ácidos):** Caracterizado por alta acidez fija y baja concentración de azúcar y dióxido de azufre.
 - Clúster 2 (Vinos Dulces y Sulfatados):** Presenta altos niveles de dióxido de azufre (libre y total) y azúcares residuales.
 - Clúster 3 (Vinos Alcohólicos de Alta Calidad):** Muestra el promedio más alto de graduación alcohólica y pH equilibrado, correlacionándose estadísticamente con puntajes de calidad más elevados.
- Visualización de PCA:** El biplot bidimensional de PCA retiene aproximadamente el 45% – 50% de la varianza total de las 11 variables químicas en solo dos dimensiones, permitiendo verificar visualmente que las particiones de K-Means están nítidamente separadas y no se traslapan significativamente en el espacio comprimido.
- Dendrograma:** El método de Ward revela la estabilidad de los agrupamientos a diferentes alturas de corte, confirmando que las subfamilias químicas se asocian de manera robusta.